HPM-DCNet：基于 CNN-Transformer 双分支与 Mamba 跨模态融合的 SAR–光学遥感影像去云网络

摘要：由于合成孔径雷达（SAR）具备全天候穿透能力，探索其与光学数据的高效融合以实现复杂场景下的遥感图像去云，已成为当前的重要研究热点。然而，现有方法多采用单一的 CNN 或 Transformer 同构网络处理多模态输入，不仅难以兼顾局部结构提取与全局长程推断，更忽视了 SAR 相干斑噪声与光学大面积信息缺失在数据退化模式上的显著差异。针对上述痛点，本文提出了一种 CNN-Transformer 双分支的跨模态 Mamba 去云网络（HPM-DCNet）。具体而言，CNN 分支旨在捕捉局部信息，并引入感受野注意力卷积块（RFAConv），以增强局部特征提取能力并有效抑制相干斑噪声。同时，Transformer 分支则捕捉全局信息，采用 SCSA 强化全局上下文与语义的一致性，从而协调了多源数据之间的模态差异。此外，进一步引入跨模态 Mamba 融合模块，通过多模态交叉选择性扫描机制，有效补偿厚云遮挡区域的结构缺失。所提方法在 SEN12MS-CR 数据集上进行了评估。实验结果表明，该框架显著优于现有模型，所提方法在去云数据集 SEN12MS-CR 上实现了先进的结果峰值信噪比（PSNR）为 32.60 dB，结构相似性指数（SSIM）为 0.924。

关键词：云去除、Mamba、跨模态融合、遥感图像重建、异构双分支网络

1 引言

光学遥感影像极易受云层遮挡，导致地表信息严重缺失，严重制约了目标检测、地物分类等下游任务的开展。由于合成孔径雷达（SAR）具备全天候、不受云雾影响的穿透成像优势，探索 SAR 与光学影像的跨模态融合去云已成为当前最为有效且备受瞩目的解决方案。

在跨模态去云任务中，高质量的特征提取是实现精准重建的先决条件。现有的主流方法通常采用单一架构提取特征：纯 CNN 网络受限于局部感受野，在面对大面积厚云时，缺乏长程上下文建模能力，难以跨越厚云遮挡区域获取有效的背景支撑；而纯 Transformer 网络虽然具备全局视野，但计算复杂度随分辨率呈平方级增长，且容易丢失地物的高频边缘与局部纹理细节。因此，如何同时兼顾“全局语义感知”与“局部结构细节”，是当前特征提取面临的一大痛点。

此外，即便获取了多源特征，由于 SAR 与光学影像在数据特性与退化模式上存在显著的模态差异，如何实现高效且深度的跨模态融合仍是一大难题。传统的浅层拼接极易将 SAR 独有的相干斑噪声引入到重建的光学图像中；而采用交叉注意力机制进行模态对齐，其计算开销会随着高分辨率遥感影像的尺寸呈二次方爆炸。为了打破上述“特征提取不全面”与“跨模态融合效率低、噪声大”的双重困境，本文提出了一种基于异构双分支与选择性状态空间（Mamba）的新型融合去云网络。

总的来说，本文的主要贡献如下：

（1）提出了一种高效的异构双分支特征提取模块。我们创新性地并行使用 CNN 和 Transformer，在浅层编码阶段解耦并同时捕获局部高频空间细节与长距离全局语义。该设计为应对大面积厚云遮挡提供了完备的多尺度特征基石，克服了单一架构的固有缺陷。

（2）设计了基于 Mamba 的选择性跨模态融合模块。针对高分辨率下跨模态特征对齐的计算瓶颈，本文将状态空间模型（SSM）引入 SAR–Optical 融合

过程。利用 Mamba 线性复杂度和选择性扫描的特性，该模块能够在大感受野下动态筛选异质特征，在高效补充 SAR 有效结构信息的同时，有效抑制了 SAR 相干斑和光学云层噪声的传递。

（3）在数据集上的实验表明，该方法在视觉质量和客观评价指标上均显著优于现有的先进去云算法。

2 方法论

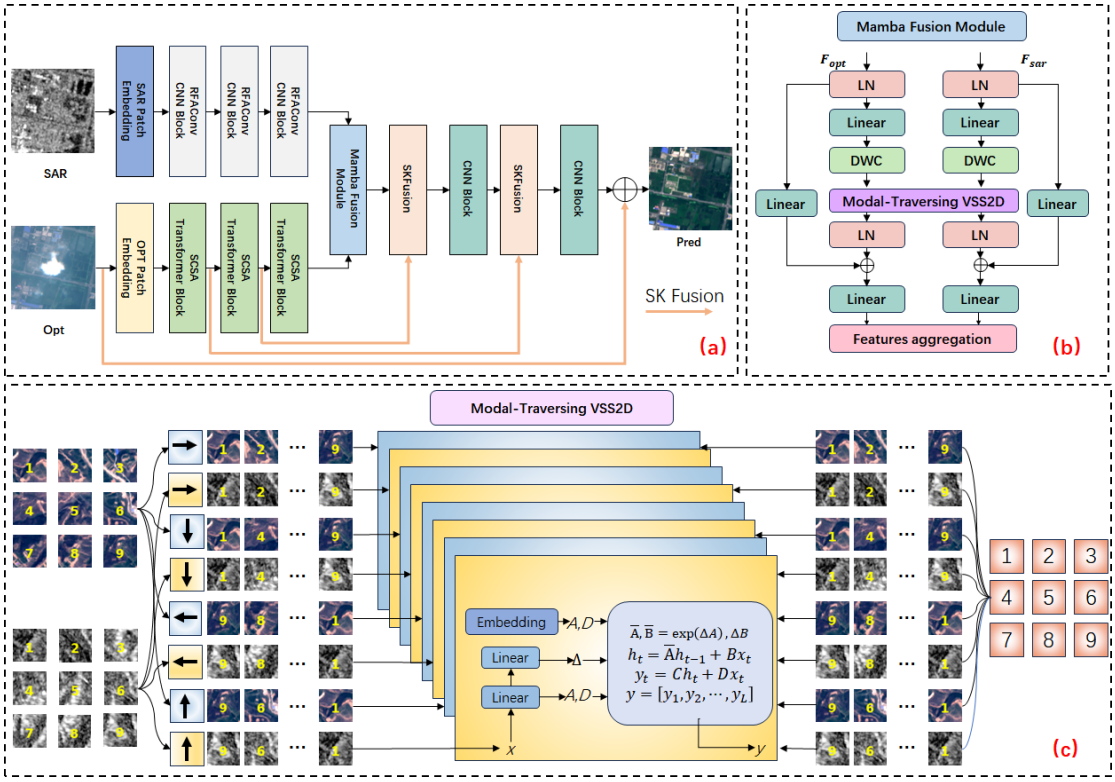

图 1 HPM-DCNet 网络框架

A. HPM-DCNet 网络框架

图 1 展示了本文所提网络（HPM-DCNet）的整体架构。如图 1(a)所示，HPM-DCNet 的主要由三个核心阶段构成：双分支异构特征提取编码器、多模态曼巴融合模块，以及渐进式解码重建模块。

具体而言，给定云层遮挡的光学图像$I_{opt} \in R^{H\times W\times 13}$与空间对齐的 SAR 图像$I_{sar} \in R^{H\times W\times 3}$。网络首先通过块嵌入操作将输入映射至浅层特征空间，分别得到初始特征 X_{opt}^{0} 和 X_{sar}^{0} 。

$$X_{opt}^{0} = embedding(I_{opt}), X_{sar}^{0} = embedding(I_{sar}) \tag{1}$$

随后，初始特征 X_{opt}^{0} 被输入到光学分支的空间-通道协同注意力（SCSA）

Transformer 模块，记作$SCSA(\cdot)$；同时 X_{sar}^{0} 被输入到 SAR 分支的感受野注意力卷积（RFAConv）模块，记作$RFA(\cdot)$。过程可形式化为：

$$X_{opt}^{1} = SCSA\left(X_{opt}^{0}\right)，X_{sar}^{1} = RFA(X_{sar}^{0}) \tag{2}$$

随着上述异构提取过程的逐级递进，光学分支生成了多层级的特征集合$\{X_{opt}^{1}, X_{opt}^{2}, X_{opt}^{3}\}$。浅、中层特征$X_{opt}^{1}$与$X_{opt}^{2}$被策略性地保留为跳跃特征，为后续的图像重建提供丰富的多尺度局部细节支撑；而最深层异质特征X_{opt}^{3}与X_{sar}^{3}则共同被送入跨模态曼巴融合模块，作为深度交互与结构补偿的基础。该深层跨模态交互过程可抽象为：

$$F_{fus} = Mamba\left(X_{opt}^{3}, X_{sar}^{3}\right) \tag{3}$$

其中，$Mamba(\cdot)$代表结合可学习绝对位置编码与多方向交叉选择性扫描的跨模态曼巴融合函数，F_{fus}为输出的深度融合特征。

随后，网络进入渐进式特征解码与图像重建阶段。在解码过程中，网络直接利用选择性核融合模块，将上一层的解码特征与对应的光学跳跃特征X_{opt}^{l}进行自适应整合，并交由 CNN 块进行局部细节的精细化重构：

$$F_{dec}^{l} = CNN\left(SKFusion\left(F_{dec}^{l+1}, X_{opt}^{l}\right)\right), l \in （1，2） \tag{4}$$

其中，$F_{dec}^{3} = F_{fus}$为解码的初始输入。通过这种跳跃融合设计，网络有效放大了底层特征中的高频纹理信息。

最后，经过充分解码的特征F_{dec}^{1}通过一个线性映射层$\omega(\cdot)$生成预测的无云残差图。基于全局残差学习理念，最终的高保真无云预测图像I^{Δ}由预测残差与原始含云输入图像I_{opt}逐元素相加得到：

$$\hat{I} = I_{opt} + \omega(F_{dec}^{1}) \tag{5}$$

B. 双分支异构特征提取模块

1) SAR 局部结构增强分支

为克服传统空间注意力在较大卷积核中参数共享的瓶颈，SAR 分支引入 RFAConv 模块，通过为感受野内的每个特征独立分配注意力权重，实现非共享参数的自适应卷积。

具体而言，给定 SAR 分支的输入特征$X \in R^{C\times H\times W}$，RFAConv 首先利用平均池化聚合每个感受野特征的全局信息，以降低计算开销。随后，通过1×1分组卷积进行信息交互，记为$g^{1\times 1}$，并利用 Softmax 函数生成感受野注意力图A_{rf}：

$$A_{rf} = \text{Softmax}\left(g^{1\times 1}\left(\text{AvgPool}(X)\right)\right) \tag{6}$$

与此同时，输入特征X利用$k\times k$分组卷积（记为$g^{k\times k}$）提取感受野空间特征，并依次经过归一化（Norm）与 ReLU 非线性激活函数处理，得到变换后的感受野特征F_{rf}：

$$F_{rf} = \text{ReLU}\left(\text{Norm}\left(g^{k\times k}(X)\right)\right) \tag{7}$$

最后，将感受野注意力图A_{rf}与感受野空间特征F_{rf}进行逐元素相乘操作，输出强化后的局部结构特征F_{out}：

$$F_{out} = A_{rf} \otimes F_{rf} \tag{8}$$

2) 光学全局语义建模分支

具体而言，给定光学分支第l层的输入特征X_{opt}^{l-1}，首先经过层归一化得到：

$$\boldsymbol{X'} = LN\left(\boldsymbol{X_{opt}^{l-1}}\right) \tag{9}$$

首先利用多语义空间注意力（SMSA）提取空间引导先验，以定位有效无云区域；随后，通过多语义通道注意力（MSCA）进行深层语义交互与特征重标定，从而有效抑制云层噪声。这两个阶段的协同更新过程可直接形式化为：

$$X_S = SMSA(X') \otimes X' \tag{10}$$

$$X_{scsa} = MSCA(X_S) \otimes X_S \tag{11}$$

其中，$\otimes$表示逐元素相乘。最终，经过空间与通道协同重标定的特征$\boldsymbol{X_{scsa}}$，结合残差连接与标准前馈网络（MLP），输出本层的更新特征$\boldsymbol{X_{opt}^{l}}$：

$$X_{opt}^{l} = \mathrm{MLP}\left(\mathrm{LN}\left(X_{scsa} + X_{opt}^{l-1}\right)\right) + \left(X_{scsa} + X_{opt}^{l-1}\right) \tag{12}$$

C.多模态曼巴融合模块

为在多模态交叉选择扫描前保留稳定的空间位置信息，本文在融合模块中引入了受 ViT 启发的可学习绝对位置编码。设光学分支与 SAR 分支的深层特征分别为$\mathrm{F_{opt}}$和$\mathrm{F_{sar}}$。

首先，两路输入特征分别经过层归一化与线性映射，并拆分为主干分支和门控分支；其中主干分支进一步经深度可分离卷积与 SiLU 激活，得到用于后续选择性状态空间建模的特征表示。

$$X_{opt} = (\mathrm{Linear}\ (\mathrm{LN}\ (\mathbf{F}_{opt}))), X_{sar} = (\mathrm{Linear}\ (\mathrm{LN}\ (\mathbf{F}_{sar}))) \tag{13}$$

$$\mathbf{X}_{opt} = \delta\left(\mathrm{DWC}\ (\mathbf{X}_{opt})\right), \mathbf{X}_{sar} = \delta\ (\mathrm{DWC}\ (\mathbf{X}_{sar})) \tag{14}$$

其中，$\delta(\cdot)$表示 SiLU 激活函数，DWC $(\cdot)$表示深度可分离卷积。

由于选择性扫描需要将二维特征展平为一维序列，原始空间坐标关系会被削弱。为此，本文在扫描前引入共享的可学习绝对位置编码，以补偿序列化带来的位置信息损失。设当前融合层主干特征尺寸为$\mathbf{X} \in \mathbb{R}^{B \times C' \times H \times W}$，其中$C'$表示融合模块内部隐空间维度，$H$和$W$分别表示当前特征图的高和宽。基础位置编码定义为：

$$\mathbf{P} \in \mathbb{R}^{1 \times L_0 \times C'}, L_0 = S_0^2 \tag{15}$$

其中，S_0为预设的基准尺寸。将当前特征图展平后可得到长度为$L = H \times W$的 token 序列；当$L \neq L_0$时，对基础位置编码沿序列维进行一维线性插值，从而得到适配当前尺度的位置编码：

$$\widetilde{\mathbf{P}} = \text{Interp}\,(\mathbf{P}, L), L = H \times W \tag{16}$$

随后，将两路主干特征展平为序列并注入同一组位置先验：

$$\widehat{\mathbf{X}}_{opt} = \text{Reshape}^{-1}(\text{Reshape}\,(\mathbf{X}_{opt}) + \widetilde{\mathbf{P}}) \tag{17}$$

$$\widehat{\mathbf{X}}_{sar} = \text{Reshape}^{-1}(\text{Reshape}\,(\mathbf{X}_{sar}) + \widetilde{\mathbf{P}}) \tag{18}$$

其中，Reshape $(\cdot)$表示将二维特征图重排为一维 token 序列，Reshape $^{-1}(\cdot)$表示恢复为原始空间结构。

随后，位置增强后的$\widehat{\mathbf{X}}_{opt}$和$\widehat{\mathbf{X}}_{sar}$被送入交叉选择性扫描模块，在原始顺序、转置顺序及其逆序方向上完成多方向状态传播。具体地，本文首先构造四个基础扫描分支：

$$\mathbf{S}_0 = \text{Stack}\,(\mathcal{V}(\widehat{\mathbf{X}}_{opt}), \mathcal{V}(\widehat{\mathbf{X}}_{sar}), \mathcal{V}(\mathcal{T}(\widehat{\mathbf{X}}_{opt})), \mathcal{V}(\mathcal{T}(\widehat{\mathbf{X}}_{sar}))) \tag{19}$$

并进一步与其逆序序列拼接，得到八路扫描输入：

$$\mathbf{S} = \text{Concat}\,(\mathbf{S}_0, \text{Flip}\,(\mathbf{S}_0)) \tag{20}$$

扫描序列 $\mathbf{S}$经选择性状态空间模块处理后，首先得到多方向扫描响应；随后将各方向输出恢复为二维特征图并进行聚合，再与门控分支共同送入卷积映射层，最终生成跨模态融合特征$\mathbf{F}_m$。

其中，$\mathcal{V}(\cdot)$表示按空间顺序展平操作，$\mathcal{T}(\cdot)$表示高宽维转置操作。该过程使两种模态特征能够在统一状态空间中进行跨方向、跨模态的长程依赖建模。

通过上述设计，所提模块能够在共享位置先验约束下完成跨模态、多方向的选择性状态传播，从而充分发挥 ViT 分支的全局语义建模能力，并更稳定地利用 SAR 结构先验补偿厚云遮挡区域中的信息缺失。

D.损失函数

为同时约束重建结果的像素级精度、结构一致性和光谱保真性，本文采用联合损失函数对网络进行训练。设网络预测的无云图像为$\hat{I}$，对应的真实无云图像为I，则总损失函数定义为:

$$\mathcal{L}(\hat{I}, I) = \alpha \mathcal{L}_{\mathrm{SmoothL1}}(\hat{I}, I) + (1-\alpha)\mathcal{L}_{\mathrm{MS_SSIM}}(\hat{I}, I) + \beta \mathcal{L}_{\mathrm{SAM}}(\hat{I}, I) \quad (21)$$

其中，α和β为平衡各损失项贡献的权重系数。该设计通过多目标约束同时提升去云结果的像素精度、结构质量和光谱一致性。

其中，SmoothL1 损失用于衡量预测图像与参考图像之间的像素级误差；MS-SSIM 损失用于增强图像在多尺度下的结构相似性，其形式为:

$$\mathcal{L}_{\mathrm{MS_SSIM}} = 1 - \mathrm{MS_SSIM}(\hat{I}, I) \quad (22)$$

同时，为进一步约束重建图像的光谱信息，本文引入基于光谱角映射的 SAM 损失，其定义为:

$$\mathcal{L}_{\mathrm{SAM}} = \arccos\left(\frac{\sum_{c,h,w} \hat{I}_{c,h,w} I_{c,h,w}}{\sqrt{\sum_{c,h,w} \hat{I}_{c,h,w}^2}\sqrt{\sum_{c,h,w} I_{c,h,w}^2}}\right) \quad (23)$$

其中，c、h和w分别表示通道、高度和宽度维度。实验中，参考相关工作设置，本文取$\alpha = 0.2$、$\beta = 0.005$。通过上述联合损失的共同约束，所提网络能够在恢复图像细节结构的同时，兼顾整体视觉质量与光谱一致性。

3 实验结果与分析

A.实验设置与实施细节

1)数据集：本文在 SEN12MS-CR 数据集上评估所提方法的有效性。我们从原有的 169 个区域中按 149:10:10 的比例，采样构建了 14,000 个尺寸为 256×256 像素的样本三元组，其中训练集包含 10,000 个样本，验证集与测试集各包含 2,000 个样本。每个三元组均由 Sentinel-2 云污染图像、时间相近的无云 13 波段多光谱图像，以及配准的 Sentinel-1 双极化 VV 和 VH 通道 SAR 图像组成。为兼顾计算效率与数据扩增，训练阶段将原始图像随机裁剪为 128×128 像素输入网络，测试阶段则保持原分辨率进行评估。

2)实施细节：实验在 Ubuntu 环境下基于 NVIDIAGeForceRTX3090GPU 完成。为保证实验公平性，所有对比方法均采用一致的参数训练。所有方法均使用 Adam 优化器，最大训练轮数设为 30epochs，批量大小设为 4。初始学习率设为 1×10^{-4}，并每 5 个 epoch 按 0.5 的衰减系数进行调整。

B.结果与分析

为全面评估所提 HPM-DCNet 的去云性能，本文将其与多种现有方法进行了比较，包括 McGAN、UnCRtainTS、SpAGAN、HPN、DSen2-CR、GLF-CR、HS2P。这些方法涵盖了生成对抗学习、SAR–光学融合、多分支特征提取以及全局—局部联合建模等不同技术路线，能够较为全面地反映当前遥感去云方法的性能水平。本文在 SEN12MS-CR 数据集上对上述方法进行了定量和定性比较，以验证所提方法的有效性。

方法	MAE↓	SAM↓	PSNR↑	SSIM↑
Mcgan	0.0345	9.56	27.66	0.789
Uncrtaint	0.0275	7.80	29.65	0.886
Spagan	0.0270	7.21	29.95	0.840
Dsen2	0.0247	6.70	30.69	0.849
Hs2p	0.0238	5.92	31.30	0.857
Hpn	0.0227	6.33	31.38	0.909
Glf	0.0192	5.72	32.13	0.906
Our	**0.0188**	**5.41**	**32.60**	**0.924**

表 I.不同方法在 SEN12MS-CR 上的定量对比结果

定量评估的结果如表 I 所示。所提出的方法在 SEN12MS-CR 上实现了 PSNR 为 32.60、SSIM 为 0.924、SAM 为 5.41、MAE 为 0.0188 的性能，超过了所有对比方法。

此外，SEN12MS-CR 数据集的定性结果在图 4 中进行了说明。我们可视化了包含不同类型与厚度云层遮挡的典型场景。在不均匀薄云与部分厚云的场景中，我们的重建结果实现了更彻底的云层去除，并在云层边界处展现出平滑自然的过渡与更优的整体色彩一致性。当面临大面积厚云遮挡时，恢复细微的地表细节极具挑战性。尽管如此，我们的方法依然能够从 SAR 图像中精准提取可靠的结构先验，从而促进大型地表结构的重建。如图 2 的第二行与第三行的复杂农田及精细地貌场景，大面积的云层遮挡导致其他多模态融合网络在重建精细纹理时显得力不从心。例如，McGAN 和 UnCRtainTS 的重建结果伴随着严重的局部模糊与大面积的灰白噪声；而 DSen2-CR 虽然去除了云层，但整体呈现出明显的偏色与过平滑现象，丢失了地表的高频细节。得益于异构双分支特征提取架构与跨模态 Mamba 融合模块的深度协同，本文方法在剔除云层干扰的同时，极大程度地保留了农田的规则几何纹理与植被的自然光谱特征，有效避免了跨模态交互过程中常见的相干斑噪声传递与颜色偏移。

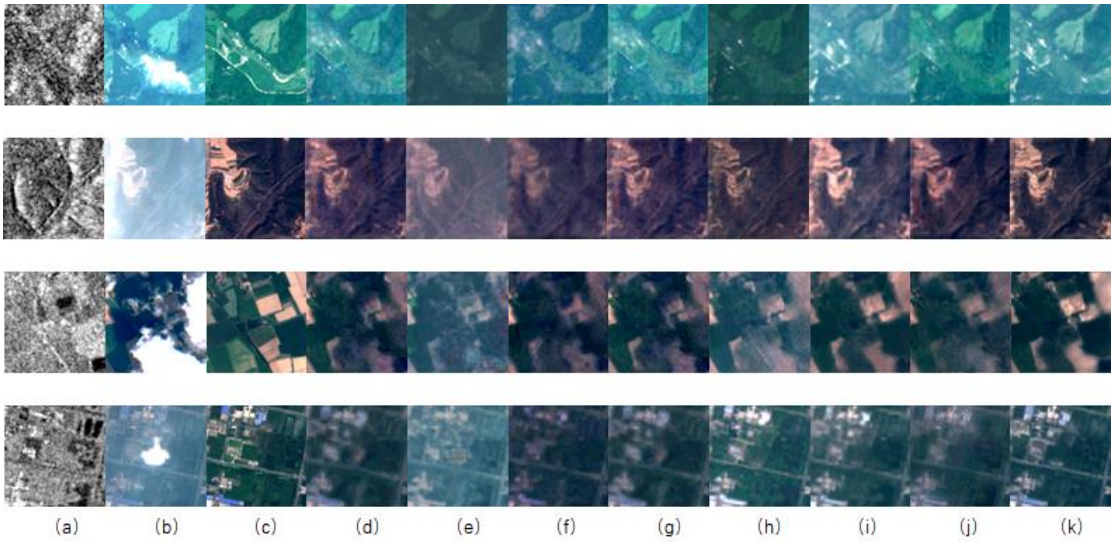

图 2.SEN12MS-CR 数据集的定性结果。(a)SAR 图像(b)多云图像(c)无云图像(d)McGAN(e)UnCRtainTS(f)SpAGAN(g)DSen2-CR(h)HS2P(i)HPN(j)GLF-CR(k)本文方法

C.消融实验

为验证所提方法中各关键模块的有效性，本文在 SEN12MS-CR 数据集上进行了消融实验。具体而言，以基础网络作为基线模型，分别引入双分支异构特征提取模块和跨模态 Mamba 融合模块，并进一步测试不同模块组合下的性能变化。评价指标采用 MAE、SAM、PSNR 和 SSIM，实验结果如表 II 所示。

双分支异构特征提取模块	跨模态Mamba融合模块	MAE ↓	SAM ↓	PSNR ↑	SSIM ↑
×	×				
√					
	√				
√	√				

表 II.SEN12MS-CR 上不同模块组合的消融研究结果

为验证所提网络中关键组件的有效性，本文在 SEN12MS-CR 数据集上进行了消融实验，结果如表 II 所示。引入双分支异构特征提取模块后，模型性能较基线网络明显提升。该模块由 SAR 分支的 RFAConv 与光学分支的 SCSA 组成，分别负责局部结构增强与全局语义建模，能够充分挖掘两种模态在结构与语义层面的互补信息，从而提升跨模态去云任务中的特征表达质量。

在此基础上，进一步引入跨模态 Mamba 融合模块后，模型性能继续提升，说明所设计的融合策略能够有效促进深层异质特征之间的交互与补偿。得益于共享位置先验与多方向交叉选择性扫描，该模块能够更稳定地将 SAR 分支中的结构信息传递到光学重建过程中，尤其有助于厚云遮挡区域的内容恢复。当双分支异构特征提取模块与跨模态 Mamba 融合模块共同作用时，模型取得了最佳结果，验证了两者之间的显著协同效应。

4 结论

本文提出了一种面向 SAR–光学遥感影像去云任务的异构并行 Mamba 网络 HPM-DCNet。该方法通过双分支异构编码器分别增强 SAR 与光学特征表征，并结合基于 Mamba 的跨模态融合模块，实现了复杂云覆盖场景下更有效的结构恢复与纹理重建。在 SEN12MS-CR 数据集上的实验结果表明，所提方法在 MAE、SAM、PSNR 和 SSIM 指标上均取得了较优性能，同时消融实验进一步验证了 RFAConv、SCSA-Transformer 和 Mamba-fusion 的有效性及协同作用。后续工作将进一步探索模型轻量化及在更多多源遥感场景下的泛化能力。

5 参考文献